SRT Commission

项目名称：基于深度学习的医学影像重建技术——以小鼠全脑冠状切面的3D重构为例

目前的注意力集中在显微镜成像下的脑组织切片的3D重建。如果有更多的组织切片当然也欢迎。

I 该领域现状：

1. NeRF 成为新视角合成的主流范式

NeRF的核心思路是渲染射线，而非整个3D模型。这使得NeRF的参数量不大（仅十万级别），计算时间较短，而且表现比传统的CNN要好。

缺点：必须知道相机的精确位姿（距离、角度），需要多张不同角度的照片，在医学情境下不现实。

2. GAN 提供强生成先验，但 3D 一致性弱

GAN（Generative Adversarial Network，生成式对抗网络）是一种非常巧妙的生图架构。由Ian Goodfellow等人在2014年提出。Goodfellow 给出的经典目标函数是：

$$\min_G \max_D V(D,G)$$

其中：

$$V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}(x)}[\log D(x)] + \mathbb{E}_{z\sim p_z(z)}[\log(1 - D(G(z)))]$$

也就是说，判别器D与生成者G都在用对方的信息更新自己的权重。这是一个双向学习、越卷越强的自我*内卷*生成器。最后，训练出的G是一个重新排布像素点的分布函数。

StyleGAN、StyleGAN2、pix2pix、GANsformer、MISS GAN 等擅长生成逼真纹理和细节。但纯 2D GAN 缺乏显式 3D 体积密度和视角一致性，容易“看起来真但转视角就崩”。于是出现了 3D-aware GAN，如 GRAF、Pi-GAN、HoloGAN、EG3D、HyperNeRFGAN。

3. 混合方法成为明显趋势

把 NeRF 的体渲染和 GAN 的生成先验结合，是当前热门方向。例如：

- GRAF：NeRF-based 通用辐射场；
- Pi-GAN：GAN + 隐式辐射场 + 体渲染；
- EG3D：StyleGAN2 + triplane 混合表示；
- MedNeRF：医学条件 NeRF；

- HyperNeRFGAN：超网络 + NeRF，处理未知位姿和动态场景；
- StyleNeRF-Med：StyleGAN2 + NeRF，面向稀疏 2D 医学视图。

这类方法试图兼顾：**生成质量、3D 一致性、稀疏视图鲁棒性、跨域泛化**。

II 我们的目标

一句话概括：**写一个不会编程的医生也能直接用的重构图像的软件。**

1. 理解医学中常用的影像来源、特点与局限

医学影像不同于一般的图片。从蕴含的信息角度，一张医学影像既有解剖学规定的器官位置、形态的普遍性，也有每个患者自己病灶形态的独特性；从图片场景的角度，普通的照片的分辨率、角度、色彩、滤镜等要素，均可由摄像师随意决定，从而获得连续的、全面的场景2D图片。与之相对的，为了减少电离辐射对人体的伤害，医学影像只能提供离散的、片面的图片，其分辨率、角度等要素受限于仪器，传统的3D图片重建技术完全不适用于这种场景。

但是，医学影像3D重建技术（medical image 3D reconstruction）的需求却一直存在。以往，我们或者根据丰富经验的专业人士的看片经验来确定病灶点位，或者干脆直接扫描一小块已知坐标的目标区域以跳过3D重建的过程。然而，以情绪研究为例，研究的目标是处理脑科学中最典型的模式动物——小鼠——的离散**全脑**切片。每张冠状切片的间隔在10–100微米不等，切片厚度在2微米左右。我们研究的对象正是全脑神经回路，只关注局部神经回路的工作不仅繁琐而且有可能丧失整体的特征，因此不能采纳“以小搏大”的策略；而现在情绪-脑神经回路二者关系的研究论文相当有限，可重复的工作非常少，更谈不上什么经验丰富。因此，这项研究就高度依赖一种“单凭有限的、离散的、视角固定的切片再加上基本的解剖学知识就能重构出小鼠大脑”的技术——医学影像自己的3D重构技术。

2. 掌握Transformer、GAN、MLP等深度学习领域经典生成模型与网络架构

在明确医学影像3D重建的实际需求之后，我们需要进一步理解近年来深度学习领域用于“从有限信息推断完整结构”的经典方法。

我们希望掌握MLP、Transformer、GAN以及后续的Implicit Neural Representation（INR）、NeRF等方法，并理解它们分别解决什么问题，而不是简单地将多个热门模型堆叠在一起。

其中，MLP帮助我们理解神经网络如何建立连续的非线性函数映射；Transformer帮助我们理解模型如何利用跨切片的全局信息；GAN帮助我们理解生成模型如何通过对抗训练学习真实数据分布；而INR和NeRF则进一步提供了一种重要的思路：**不再将三维大脑简单表示成固定大小的体素矩阵，而是直接使用神经网络表示一个连续的三维空间函数。**

最终，我们希望建立这样一种认识：

离散二维观测 → 空间关系建模 → 连续三维表示

并据此寻找适用于小鼠全脑冠状切片的三维重建方法。

3. 建立一个真正可供研究者使用的3D重建工具

本项目的成果不仅限于论文或者模型本身。

如果一个复杂的深度学习模型只能由模型开发者通过命令行、修改代码和调整参数才能使用，那么它对实际神经科学研究的帮助仍然十分有限。因此，我们希望进一步将最终的重建算法封装为一个**面向研究者的GUI（Graphical User Interface）工具**。

研究者无需理解模型内部的Transformer、GAN或NeRF，也无需编写Python代码，只需要完成：

$$\boxed{\text{导入切片} \rightarrow \text{参数设置} \rightarrow \text{自动配准} \rightarrow \text{3D重建} \rightarrow \text{可视化与导出}}$$

即可获得三维重建结果。

因此，本项目最终希望形成的不只是一个“模型”，而是一套完整的：

$$\boxed{\text{算法} + \text{数据处理流程} + \text{可视化} + \text{GUI} + \text{结果导出}}$$

从而降低深度学习医学影像重建技术的使用门槛，使其能够被没有深度学习背景的神经科学研究者使用。

III 我们的方法：从离散切片到连续三维大脑

1. 将问题形式化为“空间欠采样下的三维重建”

我们面对的数据可以表示为：

$$I_1(x,y), I_2(x,y), \cdots, I_n(x,y)$$

其中第i张切片位于：

$$z = z_i$$

因此，实际观测数据仅覆盖：

$$I(x,y,z_i)$$

而我们真正希望获得的是：

$$I(x,y,z), \quad z \notin \{z_1, z_2, \cdots, z_n\}$$

即整个连续三维空间中的影像信息。

因此，本项目并不简单地把问题定义为“图片插值”，而是将其定义为：

> **从空间上欠采样的二维医学影像中学习一个能够描述完整三维解剖结构的模型。**

---

2. 数据预处理与切片配准

在任何深度学习模型工作之前，首先需要建立可靠的三维坐标体系。

原始切片之间可能存在：

- 平移；
- 旋转；
- 缩放；
- 非刚性形变；
- 切片过程中产生的局部损伤；
- 局部组织缺失；
- 不同切片之间的成像差异。

因此，我们首先需要建立：

$$\boxed{\text{原始切片} \rightarrow \text{质量控制} \rightarrow \text{图像配准} \rightarrow \text{统一空间坐标}}$$

其中既包括刚性配准，也可以进一步探索非刚性配准。

这一步的意义不仅是提高图像质量，更重要的是：

> **确定每一张二维切片在三维脑空间中的正确位置。**

---

3. 建立传统方法baseline

在使用深度学习之前，我们首先建立传统三维重建方法作为baseline，例如：

- 最近邻插值；
- 线性插值；
- 三次插值；
- B-spline等高阶插值；
- 基于配准的重建方法。

这一阶段的目的不是追求最终性能，而是回答：

> **深度学习到底比传统方法多解决了什么问题？**

如果一个深度学习模型最终无法稳定超过简单的插值方法，那么继续增加模型复杂度就缺乏意义。

---

4. 建立深度学习baseline

在传统方法的基础上，我们进一步建立深度学习重建模型。

最基础的任务定义为：

$$I_{z_i}, I_{z_{i+1}} \rightarrow I_{z_i+\Delta z}$$

即利用相邻切片预测未观测位置的中间切片。

进一步扩展为：

$$I_{z_{i-k}}, \ldots, I_{z_i}, \ldots, I_{z_{i+k}} \rightarrow I_{z_i+\Delta z}$$

使模型能够利用更加广泛的上下文信息。

通过这一阶段，我们可以逐渐回答：

- 多少张切片能够提供足够的信息？
- 切片间距增加后，重建质量如何下降？
- 深度学习相对于传统插值方法的优势来自哪里？

IV 模型研究路线

1. MLP：建立连续空间函数

MLP是我们理解连续神经表示的基础。

传统三维医学影像可以表示为：

$$V[x, y, z]$$

而我们希望探索：

$$f_\theta(x, y, z) \rightarrow I$$

也就是说，不再让模型直接保存整个三维体素矩阵，而是让神经网络本身成为三维空间的表示。

这样，任意给定：

$$(x, y, z)$$

模型都能够预测该位置的影像属性。

这为后续的INR和NeRF类方法建立基础。

---

2. Transformer：利用跨切片信息

由于我们的数据天然具有序列结构：

$$I_1, I_2, \cdots, I_n$$

因此可以利用Transformer建立不同切片之间的关系。

模型不再只观察：

$$I_i, I_{i+1}$$

而可以利用：

$$I_{i-k}, \ldots, I_i, \ldots, I_{i+k}$$

甚至整个切片序列的信息。

我们的目标是研究：

> **全局上下文是否能够帮助模型推断局部未观测结构。**

---

3. GAN：建立生成式约束

对于医学影像而言，仅仅降低像素级重建误差并不能保证结果符合真实解剖结构。

因此，我们进一步研究GAN所提供的生成式约束：

$$G(z) \rightarrow \text{重建结果}$$

$$D(x) \rightarrow \text{判断结果是否符合真实影像分布}$$

最终形成：

$$L = L_{\text{reconstruction}} + \lambda L_{\text{adversarial}}$$

GAN在这里的作用不是简单地“让图片变得更好看”，而是探索：

> **真实医学影像的统计分布能否成为三维重建过程中的先验约束。**

并且如果可能，我们需要将解剖学ground truth“内置”到GAN中，让先验约束更符合实际。

---

4. INR / NeRF：建立连续三维脑模型

最终，我们希望进一步探索Implicit Neural Representation。

其核心思想是：

$$f_\theta(x, y, z) \rightarrow I$$

模型本身就是一个连续的三维脑。

相比固定体素表示：

$$512 \times 512 \times 512$$

这种表示方式可以在任意坐标进行查询，因此更加符合我们的最终目标：

> **从离散的切片恢复连续的三维空间。**

在此基础上，我们进一步研究NeRF类方法是否能够适应医学影像的特殊观测方式。

V 从“模型”走向“系统”

1. 建立标准化的数据输入流程

为了使未来研究者能够使用该工具，我们需要首先定义统一的数据输入规范。

用户可以导入：

- 单张或多张二维切片；
- TIFF、PNG、JPEG等常见影像格式；
- 包含空间位置信息的医学影像格式；
- 切片间距及切片厚度等元数据。

系统自动完成：

$$\boxed{\text{数据读取} \rightarrow \text{格式统一} \rightarrow \text{空间信息解析} \rightarrow \text{质量检查}}$$

---

2. 自动完成图像配准

GUI中提供：

- 自动配准；
- 手动微调；

- 配准结果预览；
- 相邻切片快速检查。

研究者不需要直接编写配准代码。

系统应该允许用户在必要时覆盖自动结果，从而避免“黑箱式自动处理”。同时，我们强调，配准算法并非百分百正确。不论采取何种处理策略，全自动配准也只能实现“得分最高”，与“实际有意义”之间仍然有差距。

---

3. 自动完成三维重建

用户选择：

- 重建方法；
- 模型；
- 输出分辨率；
- 切片间距；
- 计算设备等参数。

然后：

$$\boxed{\text{Run Reconstruction}}$$

系统自动完成模型推理，并生成三维数据。

对于普通研究者而言，他们看到的应该是：

> “选择数据 → 点击重建”

而不是：

> “配置Python环境 → 安装CUDA → 修改config → 调整模型参数 → 运行脚本”。

---

4. 三维可视化

重建完成后，GUI提供三维交互：

- 任意角度旋转；
- 缩放；
- 平移；
- 任意方向切片；

- 正交视图；
- 三维表面显示；
- 不同脑区颜色标记；
- 原始切片与重建结果对照。

尤其需要支持：

$$(x, y, z) \leftrightarrow I(x, y, z)$$

即在三维模型中选择某个位置时，可以回溯对应的二维影像。

这样可以帮助研究者判断：

> **模型产生的三维结构是否真正有原始切片证据支持。**

VI 模型评价：不仅评价“像不像”，还评价“对不对”

1. 二维影像质量

使用：

- MAE；
- MSE；
- PSNR；
- SSIM；

评价模型预测切片与真实切片之间的差异。

---

2. 三维连续性

评价组织结构沿冠状轴方向是否连续。

例如研究：

$$I(x, y, z) \rightarrow I(x, y, z + \Delta z)$$

之间的变化是否符合真实组织的空间变化规律。

---

3. 解剖学一致性

选择具有明确解剖边界的脑区作为验证对象。

比较：

- 脑区位置；
- 体积；
- 边界；
- 三维形状；
- 与相邻脑区的空间关系。

从而评价：

$$\boxed{\text{pixel-level accuracy} \rightarrow \text{anatomical accuracy}}$$

---

4. 人类专家评价

由于医学影像最终服务于生物医学研究，因此我们还需要保留人工评价环节。

邀请具有相关经验的研究者对重建结果进行盲法评价，例如：

- 结构连续性；
- 解剖合理性；
- 明显伪影；
- 局部结构缺失；
- 是否适合进一步科研分析。

这可以弥补纯数学指标无法完全描述的医学影像问题。

VII 软件工程与GUI设计

1. 设计原则：算法复杂度与使用复杂度分离

本项目希望实现：

$$\boxed{\text{内部复杂} \qquad \text{外部简单}}$$

内部可以包含：

- 图像配准；
- Transformer；

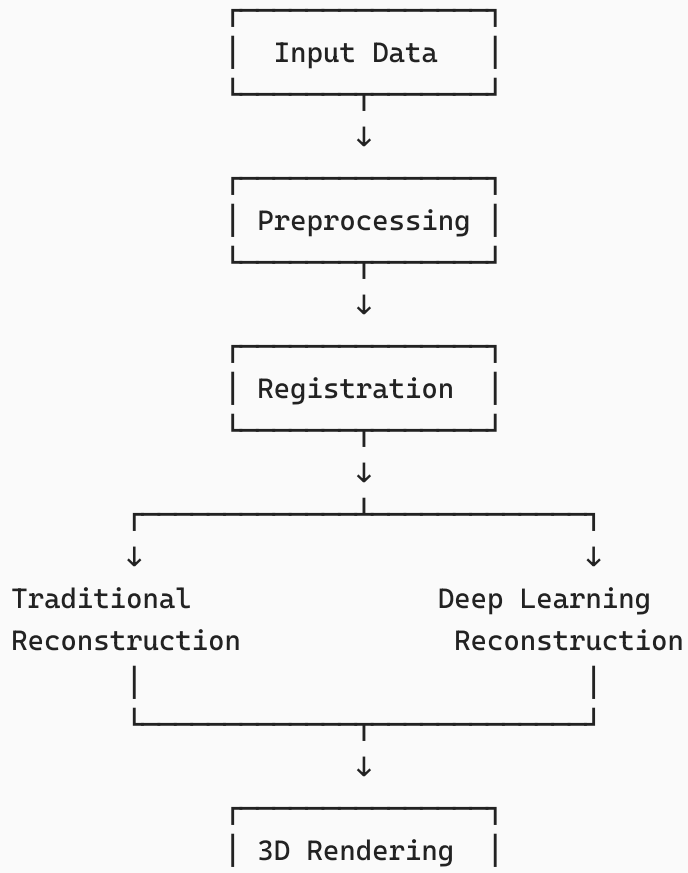
- GAN；
- INR；
- NeRF；
- GPU推理；

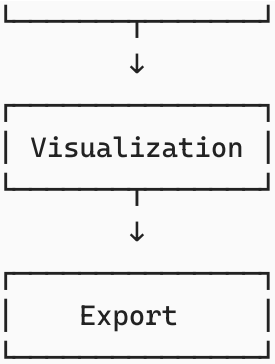
但用户界面只需要呈现：

```
数据
 ↓
预处理
 ↓
配准
 ↓
重建
 ↓
可视化
 ↓
导出
```

2. 模块化设计

软件整体可以设计为：





其中每个模块彼此独立。

这样未来即使将：

> Transformer → Diffusion Model

或者：

> NeRF → 新的Implicit Representation

也不需要重新设计整个软件。

3. 保留命令行/API接口

GUI并不意味着放弃代码接口。

我们希望同时提供：

$$\boxed{GUI + CLI + Python\ API}$$

GUI服务于不具备编程背景的研究者；

CLI适合批量处理大量小鼠脑数据；

Python API则允许其他研究者把我们的算法进一步整合到自己的科研流程中。

这样，项目成果就不仅是一个“软件窗口”，而是一套可复用的研究基础设施。

VIII 最终成果

本项目最终希望形成三个层次的成果。

第一层：算法

建立一套能够从：

离散小鼠全脑冠状切片

$$\boxed{\text{离散小鼠全脑冠状切片}}$$

重建：

连续三维全脑结构

$$\boxed{\text{连续三维全脑结构}}$$

的深度学习方法。

第二层：软件

将算法封装成：

可视化、可交互、低门槛的GUI工具

$$\boxed{\text{可视化、可交互、低门槛的GUI工具}}$$

使没有深度学习背景的神经科学研究者也能够使用。

第三层：科研基础设施

提供：

- 完整源代码；
- 训练好的模型；
- 数据预处理工具；
- GUI；
- Python API；
- CLI；
- 使用文档；
- 示例数据；
- 模型评价工具。

最终形成：

$$\boxed{\text{Data} \rightarrow \text{Reconstruction} \rightarrow \text{Visualization} \rightarrow \text{Analysis}}$$

的一体化工作流。

VIII 最终愿景

因此，本项目最终的核心产物可以概括为：

而深度学习模型只是这个平台的核心引擎之一。

我们最终希望实现的目标，是让“从大量离散脑切片到完整三维全脑”的过程，从一个高度依赖专业经验、编程能力和大量人工操作的科研流程，逐渐转变为一个**标准化、自动化、可重复、可扩展的研究工具**。